

基于多特征提取和多分类器的轴承故障检测

许肖汉¹, 杨玉林¹, 郑鹏宇¹

1. 北京理工大学 自动化学院, 北京 100081

E-mail: 1120171187@bit.edu.cn

摘要: 随着各行各业对旋转机械需求的不断增加, 为保证旋转机械能处于一个健康的工作状态, 一个系统化智能化的滚动轴承检测系统是很有必要的。因此, 一些新型并能提高精度的轴承故障检测的诊断方法需要测试、开发。根据此需求, 本文提出了一种基于多特征和多分类器的故障诊断系统, 该系统具有较高的诊断准确率。为了有效地分析滚动轴承的故障信息, 提取和选择关键特征仍然适合于轴承诊断。同时, 为了建立一个综合性、具有鲁棒性的系统并能解决仅从时域和频域角度处理原始信号所带来的缺陷, 本文采用了一种组合时域、频域和小波包分解的多特征提取方法, 随后使用主成分分析(PCA)来进行降维。该诊断系统有多个在有监督环境下训练的分类器, 包括k-最近邻(KNN), 支持向量机(SVM)和随机森林(RF)。最终的实验为基于DC数据平台的轴承数据, 比较了不同分类器处理不同特征组合方法的准确率结果。结果表明, 本文所提出的系统具有较强的鲁棒性和较高的检测精度。

关键词: 滚动轴承, 故障诊断, 小波包变换, K近邻算法, 支持向量机, 随机森林算法, 主成分分析

Bearing Fault Detection Based on Multi-feature Extraction and Multi-classifiers

Xiaohan Xu¹, Yulin Yang¹, Pengyu Zheng¹

1. Academy of Automation, Beijing Institute of Technology, Beijing 100081

E-mail: 1120171187@bit.edu.cn

Abstract: With the increasing demands of rotating machinery, a systematical and intelligent diagnosis system of rolling bearing, the key part of rotating machinery, is needed necessarily to keep machine at a healthy working state. Therefore, some new methods to detect the bearing fault and improve the accuracy should be tested. Based on that, a new fault diagnosis system based on multi-feature and multi-classifier is proposed, which can reach a high accuracy. To effectively analyze the fault information of rolling bearing, extracting and selecting key features are still suitable for bearing diagnosis. At the same time, to address the drawback of processing the raw signal by time domain or frequency domain, a combined multi-feature of time domain, frequency domain and wavelet packet decomposition are applied to build up an overall and robust system and then principal component analysis (PCA) is used to reduce the feature dimension. The diagnosis system is performed by several classifiers, including k-nearest neighbor (KNN), support vector machine (SVM) and random forest (RF) in a supervised environment. Experiments are performed by using above-mentioned classifiers to compare different approaches of feature combination based on datasets of DataCastle. Results demonstrates that the proposed system are robust enough and accurate to detect the fault of rolling bearing.

Key Words: rolling bearing, fault diagnosis, wavelet packet decomposition (WPT), k-nearest neighbor (KNN), support vector machine (SVM), random forest (RF), principal component analysis (PCA)

1 引言

在我国科技发展历程当中, 制造业一直是我国所重视的产业, 而且我国的制造业正向智能化、精确化、高速化飞速地发展。制造业或机械应用中的旋转机械在各个应用领域中有着举足轻重的作用, 其经常被作为高端制造的重要成分。随着科技的不断发展以及对旋转机械的研究, 这种机械结构的应用变得越来越精确但复杂。同时, 由于旋转机械长时间地工作, 一些不可避免的故障便会出现, 若出现故障没有得到及时筛查, 其将会带来巨大的安全隐患以及高昂的维修费用。而旋转机械中的常见的故障是滚动轴承故障, 其占据了旋转机械常见故障的近三成。因此, 探究检测

滚动轴承故障的方法一直是该领域大家所关注的焦点问题。但由于滚动轴承在运动时, 其振动信号噪声过多且不平稳, 而且会出现不同形式的故障, 这便导致在早期的时候人们对该问题无法设计出一套令人满意的方法。因此, 提出一种高效且行之有效的滚动轴承故障检测的方法至关重要, 解决该问题能够使工作人员及时发现故障, 并且通过辨别故障类型, 从而采取与之对应的修补方法来实现高端机械产品的长期正常运行, 减少了因过度损坏而带来的巨大的经济损失。

目前该领域相关的工作较为丰富。轴承故障检测的问题实际上便是一个模式识别的问题, 特征提取和分类器检测是该系统中的两个重要环节, 因此相关的

工作主要存在于特征提取方法以及分类器的设计上。特征提取方面,由于振动信号包含着丰富的信息,不同的故障能够产生不同的周期性的故障信号,因此轴承运动的振动信号经常被用来作为特征提取的原始数据。然而,直接对原始振动信号做非常困难而且准确率低下,这是因为原始信号包含着各种复杂的信息以及噪音。因此,特征提取是处理振动信号前的必要方法。特征提取的主要方法包括时域分析、傅里叶变换、时频域分析的小波变换、小波包分解以及经验模态分解(EMD)等方法^[1]。时域分析法主要是将时域的一些如平均值、标准差、峭度等的特征计算出来作为信号特征。傅里叶变换是将信号变换到频域上去分析,从而可以提取出时域所缺少的特征。小波变换能够将原始的时域信号变换到时频域上,提取出信号的局部特征、提供信号的时间尺度信息、提取随时间变化的特征,因此其能很好地处理非平稳信号。其中离线小波变换(DWT)相较于离散小波变换具有重构准确和无冗余的特点,能充分展现故障的时频特征^[2]。彭成团队就使用了该方法利用离散小波变换分解轴承振动信号并结合 sigmoid 熵构造出n 维特征向量作为每个样本的特征,其能提取较好的非平稳信号特征信息,从而提高准确率^[3]。经验模态分解(EMD)是一种基于局部时间尺度的自适应时频域分析方法。EMD能够将信号分解成一系列包含不同频带宽的内在模函数(IMFs),其表征了不同的故障信息。彭宅铭团队在他们的轴承检测方法中使用了EMD的改善方法自适应白噪声完备经验模态分解(CEEMDAN)来进行特征提取^[1]。

分类器方面,处理手工提取的特征的常用方法有k近邻(k nearest neighbor, KNN)^[4]、随机森林(random forest, RF)^[5]、支持向量机(support vector machine, SVM)^[6]等。Zuqiang Su 等人的团队使用正交SVM(LS-SVM)输入EMD特征进行轴承检测^[7]; Ying-Kui Gu 团队使用SVM结合PCA并依据傅里叶变换以及小波包分解进行轴承检测^[8]。除了用以上分类器对特征进行处理以外,另外还有一些不需要特征提取的分类器。如Guo团队提出的基于健康指示器的循环神经网络(RNN-HI)^[9]; Bach Phi Duong团队建立了一个基于去噪自动编码互斥分类器(denoising autoencoder non-mutually exclusive classifier, NMEC)的深度神经网络(deep neural network, DNN)^[10]。

基于以上所述的特征提取方法以及分类器的设计,本文提出了一种基于时域、频域和时频域三种特征结合以及多种分类器实现分类的轴承故障检测系统。本文的文章结构如下,第一部分将对所提出的系统进行一个总地概述;第二部分,系统中的每一个部分都会得到详细的阐述,包括理论以及具体的实现方法;第三部分,本文提出的系统架构将会在DC轴承公开数据集上进行实验。实验结果表明,通过结合时域、频域和时频域并使用随机森林分类器将会得到一个很高的检测准确率并且运行速度较为快速,从而证明该轴承故障检测系统是有效的。

2 模式系统架构

阶段1: 原始振动信号需经过小波软阈值方法降噪处理,减小过拟合风险。

阶段2: 利用时域、频域、时频域的方法将特征提取出来,形成一个待选择组合的特征集合,为后续分类器实验做准备。

阶段3: 根据后续分类器实验条件,选择对部分特征组合进行不同目标维数的PCA降维,或不经降维直接用于分类器实验。

阶段4: 在给定样本集中按一定比例划分分类器实验所需的训练集、测试集,用三种分类器进行实验,并记录正确率。

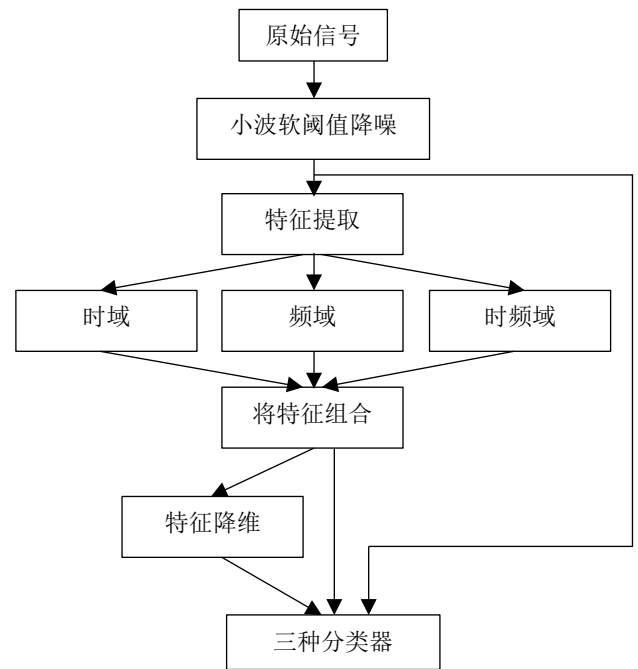


图1. 模式系统架构及实验流程

3 主要方法

3.1 降噪

原始信号中存在大量噪声,噪声可以表示成如下形式^[11]:

$$y(t) = f(t) + n(t) \quad (1)$$

其中, $y(t)$, $f(t)$, $n(t)$ 分别表示夹杂着噪音的原始信号,原始信号以及噪音信号。本文使用的去噪方法为小波软阈值去噪法,其去噪流程如图2所示。




图2. 小波阈值去噪策略

含噪信号先在各尺度上进行小波分解,对于小尺度的分解值,通过设定一个阈值实现对较小的小波系数过滤掉,最后将处理后的小波系数通过逆小波变换进行重构。该方法需要确定三个关键的参数:小波基、

分解层数以及合适的阈值函数。小波基以经过。阈值函数此处采用了软阈值函数^[12]。

$$w_{\lambda} = \begin{cases} [\text{sign}(w)](|w| - \lambda) & |w| \geq \lambda \\ 0 & |w| < \lambda \end{cases} \quad (2)$$

式(2)为软阈值函数，其中w为小波系数，w_λ为经过阈值后的小波系数，λ为阈值。

3.2 特征提取

3.2.1 时域信号特征提取

根据我们从资料中了解的轴承受损的原因，通过计算了解，样本的如下9个时域特征^[13]可以反应轴承不同类型的损坏方式。

平均值 \bar{x} 描述了采取的信号的中心趋势；数据方差 σ_x^2 描述了采取信号在均值周围的散布程度，公式如下；均方根值 X_{RMS} 与轴承表面波纹等缺陷引起的无规则振动波形的异常有较好的相关性；峰值 X_{peak} 反映了信号偏离平均值的程度；峰值因子 C_f 表示波形是否有冲击的指标；峭度系数 K_v 表示轴承振动信号振幅的规则性，当过大时则意味着有故障出现；脉冲因子 I_f 反映了振动脉冲的频率；裕度系数 CL_f ，反映信号冲击程度的一个指标，对轴承的冲击故障较为敏感；波形因子 S ，可用来判定滚动轴承的损伤类型，对于不同的损伤类型， S 差别较大。九个波形特征如表1所示，对于不同的轴承故障呈现出不同的波形效果，实现了特征提取的目的。

表1. 时域特征计算公式

特征编号	计算公式	特征编号	计算公式
01	$\bar{x} = \frac{1}{N} \sum_{n=1}^N x_n$	06	$K_v = \frac{\sum_{i=1}^N x_i^4}{N X_{RMS}^4}$
02	$\sigma_x^2 = \frac{\sum_{i=1}^N (x_i - \bar{X})^2}{n}$	07	$I_f = \frac{X_{peak}}{\frac{1}{N} \sum_{i=1}^N x_i }$
03	$X_{RMS} = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2}$	08	$CL_f = \frac{X_{peak}}{(\frac{1}{N} \sum_{i=1}^N \sqrt{ x_i })^2}$

04	$X_{peak} = \frac{1}{2} (\max(x_i) - \min(x_i))$	09	$S = \frac{X_{RMS}}{\frac{1}{N} \sum_{i=1}^N x_i }$
05	$C_f = X_{peak} - X_{RMS}$		

3.2.2 频域信号特征提取

对轴承信号采用频域分析是常用的数据分析方法之一。本文利用快速傅里叶（FFT）方法得到信号频谱，进行进一步的特征提取。但由于频域特征对早期轴承故障不敏感^[14]，所以一般的轴承故障检测中频域特征维数并不多，一般只提取重心频率，均方频率，频率方差等特征。在[15]中，作者详细列出了13个频域特征及其计算方法。在本文中，我们选取以下9个特征，其中比较常见的有重心频率，方差频率，偏态等：

表2: 频域特征计算公式

特征编号	计算公式	特征编号	计算公式
01	$FC = \frac{\sum_{i=1}^N f_i P_i}{\sum_{i=1}^N P_i}$	06	$CP1 = \frac{\sum_{i=1}^N (f_i - FC)^3 P_i}{N(STDF)^3}$
02	$VF = \frac{\sum_{i=1}^N (f_i - FC)^2 P_i}{\sum_{i=1}^N P_i}$	07	$CP2 = \frac{STDF}{FC}$
03	$MSF = \frac{\sum_{i=1}^N f_i^2 P_i}{\sum_{i=1}^N P_i}$	08	$K = \frac{\frac{1}{N} \sum_{i=1}^N (f_i - \bar{f})^4}{\left(\frac{1}{N} \sum_{i=1}^N (f_i - \bar{f})^2\right)^2}$
04	$RMSF = \sqrt{MSF}$	09	$S = \frac{\frac{1}{N} \sum_{i=1}^N (f_i - \bar{f})^3}{\left(\frac{1}{N} \sum_{i=1}^N (f_i - \bar{f})^2\right)^{\frac{3}{2}}}$
05	$RVF = \sqrt{VF}$		

其中, p_i 是经过降噪后时域信号的频谱, $i=1,2,3,\dots,N$, N 是频谱数, f_i 是第 i 条谱线的频率值, $STDF = \sqrt{\sum_{i=1}^N (f_i - FC)^2 p_i / N}$.

此外,我们还采用了取分段最大值的方法,将频谱分为100段,提取了每段频谱的最大值,得到了第二种频域特征向量。该方法在实验中取得了较好效果。

3.2.3 小波包分解

小波包分解(wavelet packet decomposition, WPT)是典型小波变换的一种,本文使用的是小波能量作为信号的特征。现如今, WPT对于轴承、齿轮故障诊断和检测都是一个强有力的工具。本文所采用的小波基为彭城团队所采用的Biorthogonal族的bior3.9^[2]。在小波包分解中,细节系数(detail coefficients)在第一层被分解从而产生小波包树(wavelet packet tree)该过程如图3所示。通过该过程,更好的时域和频域分辨率能得到。^[16]




图3. 小波包分解树(三层分解)

小波包变换如公式(3)所示:

$$x_p^{n,j} = 2^{-j/2} \int_R x(t) \mu_n(2^{-j}t - p) dt \quad (3)$$

其中 $\mu_n(t)$ 是小波函数, j 表示分解层数, p 表示位置参数, n 是分解的包的数量。对于通过小波包分解的信号 $x_p^{n,j}$, 其经常表示如下^[17]:

$$\begin{aligned} W_{2n}(t) &= \sqrt{2} \sum_l h_l W_n(2t-1) \\ W_{2n+1}(t) &= \sqrt{2} \sum_l g_l W_n(2t-1) \end{aligned} \quad (4)$$

使用小波能量作为信号的特征相较于直接使用小波分解的参数有更好的鲁棒性。能量被定义如下:

$$E_i = \int_{-\infty}^{+\infty} x_j^i(t) dt \quad (5)$$

信号的小波总能量表示如下:

$$E_{tot} = \sum_{i=1}^{2^j} E_i \quad (6)$$

本文使用小波包分解的能量值作为信号的特征。

3.3 降维方法

在得到一系列特征后,我们通过特征相关性矩阵对一部分特征的相关性进行了分析,并选用主成分分析(PCA)法进行特征降维。主成分分析能够将高维特征空间中的特征投影到较低维度的特征空间,是一种常用的特征降维方法。主成分分析剔除了隐藏在信

号中的随机成分,增强了有用的特征信息。^[18]在此基础上,有KPCA等改进型方法^[19,20]。

PCA的具体步骤为:

i. 待降维的原特征向量有 n 维, 记为: $\mathbf{x} = [x_1, x_2, \dots, x_n]$, 计算其均值

$$E = \frac{1}{n} \sum_{i=1}^n x_i \quad (7)$$

ii. 计算特征向量的协方差矩阵

$$\mathbf{C}_x = \frac{1}{n} \sum_{i=1}^n (x_i - E)(x_i - E)^T \quad (8)$$

iii. 计算协方差矩阵的特征值 λ_a 和特征向量 ξ_a

$$\mathbf{C}_x \xi_a = \lambda_a \xi_a \quad (9)$$

ξ_a 代表了原始特征空间中方差最大的方向,完整的PCA还包括设定累计贡献率下界筛选主成分数目的步骤,但本文问了探究不同程度的降维对分类正确率的影响,直接设置了降维结果的特征维数。

3.4 分类器介绍

3.4.1 随机森林

随机森林(Random forest, RF) 是一系列树构成的结构分类器 $\{C(X, \theta_k), k = 1, \dots\}$, 其中 θ_k 是独立同分布的随机向量, 决策时每棵树都会对输入进行投票决策。决策树的结构如图4所示, 其流程如下^[21]:

步骤一: 通过bootstrap 采样方法将 k 个样本采样出来。

步骤二: k 个决策树通过 k 个样本进行学习同时得到 k 个分类结果。

步骤三: 根据 k 个分类结果, 最终分类结果得到确定。

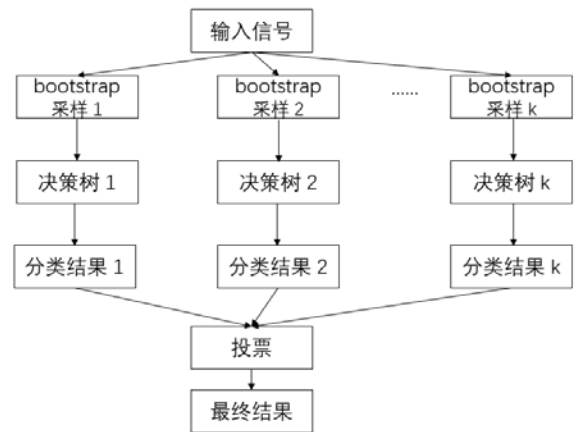


图4. 决策树结构

3.4.2 近邻分类器

K近邻分类器(K-Nearest neighbor, KNN)是一种简单的有效的分类器。K近邻分类器在滚动轴承早期故障诊断方面,能够有效地提取滚动轴承早期故障的低维敏感特征,而且结构稳定,诊断精度高,是一种非常有效的非参数化分类器。^[24]其基本原理是在特征

空间中,通过计算待分类样本与已知样本的欧氏距离加以判别,取K个最近的已知样本,再用投票的方法,将待分类样本归入这K个样本占比最高的那一类中。在此基础上,衍生出了许多KNN的改进版本,均有在轴承故障检测领域的应用。^[22,23,24] 本文为了对比几种分类器,只使用了最基本的KNN分类器。

3.4.3 支持向量机

支持向量机(Support Vector Machine, SVM)^[25]是由俄国统计学家瓦普尼克提出来的有监督学习方法。支持向量是指距离分类决策边界最近的那些样本,它们对于最终求取最优权向量有决定性作用。而SVM的训练不需要依赖于大量样本,仅依据支持向量机决定;同时SVM具有很强的泛化能力,有助于分类的准确性。对于轴承检测的实际问题,我们无法确定其线性可分性,我们需要考虑使用软间隔支持向量机与非线性支持向量机的情况。在软间隔支持向量机中,我们需要考虑异常点,即噪声干扰下的情况。我们引入松弛变量 ξ 的概念,使得我们的判别函数绝对值允许小于1,最终我们可以将最短权向量的二次优化目标和判别函数更新成如下状态:

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \xi^{(i)} \quad (10)$$

$$\text{sgn}(\mathbf{G}_{ij}(\mathbf{x}^{(li)}))(\mathbf{w}^T \mathbf{x}^{(li)} + \mathbf{w}_0) \geq 1 - \xi^{(li)} \quad (11)$$

其中C是惩罚因子,表示我们对于存在异常点的容忍程度。在非线性分类的情况中,我们使用了核函数,即可以将两个低维空间输入转化为同一个映射到另外一个空间后的内积的函数,来构建判别函数。高斯型的径向基核函数^[26]:

$$K(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}) = \exp\left(-\frac{\|\mathbf{x}^{(i)} - \mathbf{x}^{(j)}\|^2}{2\sigma^2}\right) \quad (12)$$

是我们本次实验中打算采取的一种核函数,至此我们完成非线性分类器的构建。

4 实验及结果

4.1 数据集信息

数据集来自于DC平台提供的轴承故障检测数据集,数据集包含训练集与测试集两部分。数据集中,平台结合了轴承的三种直径发生的外圈故障,内圈故障和滚珠故障三种不同的故障与正常将轴承的数据分为了10类,并将每种不同的故障类型进行标号,分类结果如表3所示;同时,在训练集中,我们获得了792个样本每个样本的6000个时域信号,以及样本最终的分类结果标签,如表4所示;在给定的测试集中,我们收到了529个样本,每个样本含6000个时域信号,如表5所示,最终需要依据训练集训练出的分类器对测试集进行分类,从而实现对于故障类型的判断。在使用数据集训练时,我们将训练集数据按7: 3的比例分开,70%的数据用于训练分类器,剩余30%的数据集用于测试分类的精确度。

表3: 轴承故障类别

	外圈故障	内圈故障	滚珠故障	正常
直径1	1	2	3	0
直径2	4	5	6	
直径3	7	8	9	

表4: 训练集数据

数据id	数据特征				标签
	1	2	...	6000	
1	0.56365	1.069229	...	0.021523	7
2	0.061333	0.05883	...	0.129342	0
...
792	0.091613	0.037847	...	-0.19882	3

表5: 测试集数据

数据id	数据特征			
	1	2	...	6000
1	0.034517	0.087715	...	-0.0402
2	-1.98171	0.483651	...	0.259084
...
528	0.125795	0.106185	...	0.049025

4.2 小波软阈值去噪处理结果

原始信号被处理前通过小波软阈值方法去除噪声信号。本文尝试了多种小波函数以及阈值,最终选取了Daubechies8小波函数以及阈值为0.1的小波软阈值方法来实现去噪。去噪前后的效果对比如图5上下部分所示。

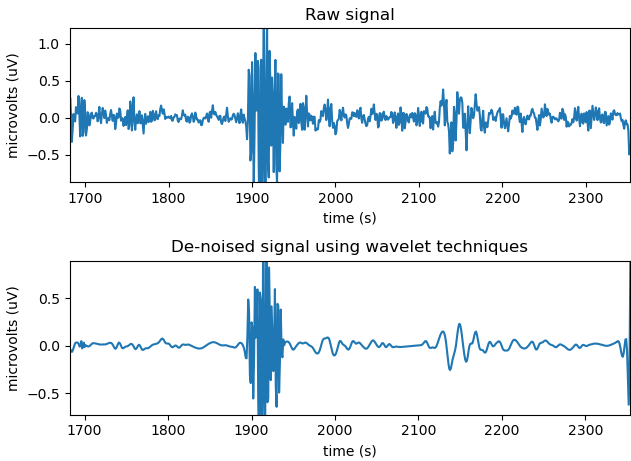


图5. 去噪前后对比图, 上图为原始信号, 下图为去噪信号

4.3 征提取结果

4.3.1 时域特征提取结果

依据表格6中的相关公式, 我们使用python语言以及pandas库对训练集中的相关数据进行处理, 提取出相关的9个特征, 得到如下数据:

表6: 时域数据特征

数据id	数据特征				标签
	ave	var	...	sf	
1	0.004765	0.340345	...	1.624946	7
2	0.015331	0.004322	...	1.245317	0
...
792	0.018271	0.01335	...	1.282835	3

为了验证提取的时域特征在不同类别之间的区分性是否足够强，我们从九种时域特征中选取了提取的四种不同的特征，同时随机抽取了10个不同故障类别的一个样本进行比较，结果如图6。从中我们可以看出，对于大部分不同的类别标签，不同特征的差别较为明显，但仍有部分的标签的数据较为类似（如6和7），因而还需要频域或时频域上的特征提取。




图6: 多种故障类型下的四种时域特征值

4.3.2 频域特征提取结果

首先我们观察频谱图的分布，如图7所示，直观体现了不同故障类型之间及其与正常轴承信号之间的显著区别，接着我们提取了其频域特征。如表8所示，在训练集中每类挑选两个数据样本，列出其特征向量值。




图7: 随机抽取的不同类型数据的频谱图

表8: 不同类型数据频域特征提取的结果

样本标签	数据ID	频域特征向量			
		FC	VF	...	Skewness
0	2	93.49405	8933.865	...	1.410887
	6	93.00017	8526.556	...	1.410626
1	42	236.7085	8872.27	...	0.271871
	57	229.6835	9149.212	...	0.411117
2	9	208.1542	9933.31	...	0.790874
	16	210.672	10546.52	...	0.750988
3	113	224.0716	12545.9	...	0.517819
	115	231.5868	12322.87	...	0.373945
4	21	235.8895	10545.3	...	0.288372
	33	230.3246	10931.76	...	0.398647
5	32	243.8321	10235.82	...	0.126204
	72	248.945	9422.054	...	0.020195
6	54	226.4501	7255.433	...	0.473157
	59	225.9217	7688.647	...	0.483153
7	1	268.4692	8061.007	...	-0.37832
	5	257.006	8037.124	...	-0.14693
8	29	243.7153	14856.34	...	0.128617
	36	246.2796	15566.26	...	0.075539
9	3	246.155	8902.391	...	0.078123
	4	234.5687	8787.41	...	0.314849

如表8所示在训练集中每类挑选两个数据样本，列出其特征向量值。对每一个样本而言，其频域特征是一个九维的向量。更直观地，如图8，我们选择三种量纲相同的频域特征，随机抽取10个不同类型数据做柱状图。可以发现，重心频率在轴承正常（类型0）与故障（类型1-9）之间有显著不同，而在其他方面，靠人的直观感受并不能很好判断，分类器结果也表明频域特征的结果相对较差。




图8: 十种类型数据部分频域特征的柱状图

接着，我们尝试了提取分段最大值方法，如表9所示，每个样本得到了100维的频域分段最大特征向量。更直观地，如图9，我们分别做了正常数据（类型0）、外圈故障（类型7）、内圈故障（类型2）、滚珠故障（类型9）的分段频域最大特征向量折线图。可以发现，不同类型分段最大值分布相差明显，也在分类器实验中取得了较好结果。




图9: 不同类型数据频域分段最大值折线图

表9: 不同类型数据频域分段最大值特征提取的结果

样本 标签	数据 ID	频域特征向量			
		01	02	...	100
0	2	91.98311	107.0326	...	0.058089
	6	86.80424	85.59699	...	0.044219
1	42	24.51325	2.403696	...	0.061873
	57	28.68978	2.335345	...	0.144622
2	9	26.80537	1.441669	...	0.096212
	16	25.51304	3.100326	...	0.027651
3	113	25.45115	2.471143	...	0.062887
	115	132.9372	2.994477	...	0.083575
4	21	27.22234	1.829626	...	0.112662
	33	84.61132	4.197005	...	0.247533
5	32	155.385	2.785601	...	0.288736
	72	18.47147	2.425852	...	0.081679
6	54	16.22321	2.405386	...	0.098288
	59	62.18017	2.678453	...	0.881325
7	1	28.58939	8.650655	...	0.400916
	5	79.54789	3.512167	...	0.316728
8	29	14.9121	2.056247	...	0.097493
	36	70.8495	3.21216	...	0.179542
9	3	19.6177	5.138505	...	1.675826
	4	24.1541	3.541403	...	0.020383

4.3.3 小波包能量特征提取结果

能量特征提取前需要对信号进行小波包分解，为了能够得到较多的能量特征，本文选择对信号数据进行6层小波包分解，从而得到64个能量特征。

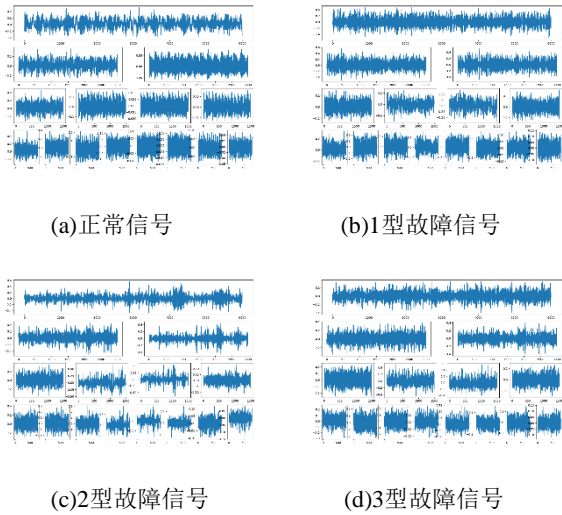


图10. 四种不同故障信号的三层小波包分解

考虑读者方便阅读，本文只列出了四类信号小波包分解到三层的情况，如图10所示，其中(a)，(b)，(c)和(d)分别代表正常信号、1型故障信号、2型故障信号以及3型故障信号的三层小波包分解波形。对信号进行小波包分解后，选取其最后一层64个能量特征作为信号的特征信息，如图11所示。

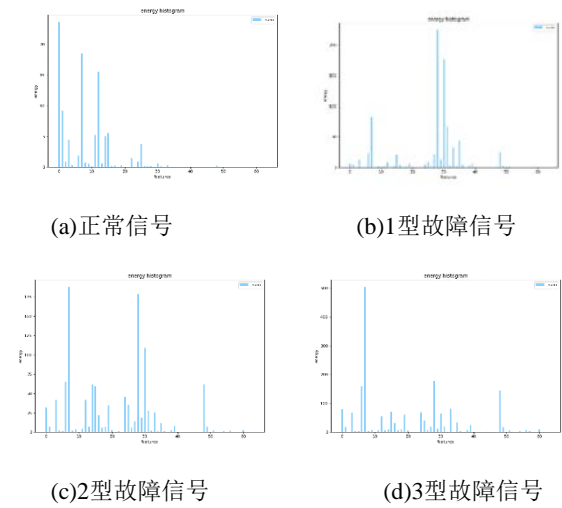


图11. 四种不同故障信号的能量特征

图11中(a)，(b)，(c)和(d)分别代表正常信号、1型故障信号、2型故障信号以及3型故障信号提取的64个能量特征。从图6中可以看出，不同信号的小波包分解所提取的64个能量信号具有着很明显的区别。

4.3.4 相关性分析及PCA降维

在得到了所有特征后，本文通过计算所有特征的相关性矩阵来判断是否有必要做降维操作。由于特征较多，这里只展示时域和频域的特征之间的相关性热力图，如图8所示，每个值代表两个特征之间的相关性。由图8可知，相关度较大的特征的数量较多，因此接下来将会对特征进行PCA降维操作。




图12. 时域和频域特征之间的相关性热力图

主成分分析时，我们除了在数据处理时将特征维度降到设定的实验维数之外，还将部分特征组合的维度将至三维，进行了可视化。如图13，可以发现时域+频域特征的PCA效果明显比单一时域特征PCA效果更好，频域分段最大特征在降到3维时，降维效果并不明显，可分性较差。

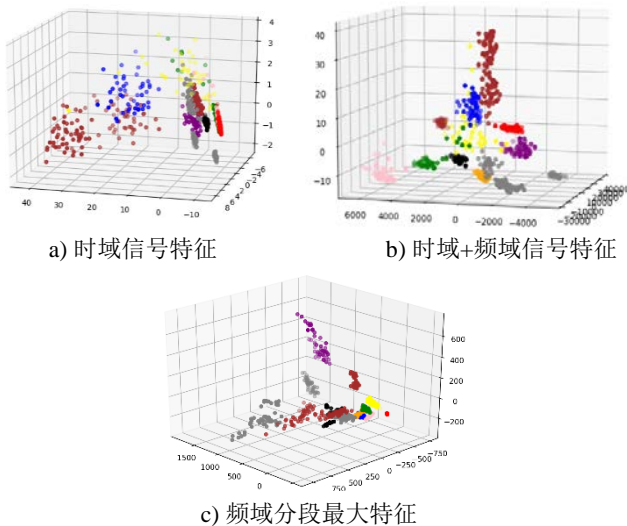



图13: 不同特征（组合）PCA结果可视化


4.4 不同分类器对于不同特征的实验结果与分析

4.4.1 K近邻分类器实验结果与分析

如图14，我们首先探究了参数K取值对分类效果的影响，结果发现K取值较小时精度更高，符合KNN算法的本质规律。一般地，取K在5以内分类正确率最高。接下来的实验中，我们取定K为2。



a) 时域特征+频域特征



b) 时域特征+频域特征+时频域特征

图14: 不同特征组合下KNN分类正确率与K的关系

接着我们探究了KNN分类器在不同特征向量组合上的正确率，如表10所示，我们得出以下结论：

时域原始信号直接分类处理，不经过特征提取的正确率远低于有特征提取步骤的识别方式。这是原始时域信号的相位差导致的。

时域、频域、时频域（小波包变换处理）得到的合并特征的分类正确率高于各自单独分类的正确率，说明合并不同提取方式的特征能有效提高分类正确率，但也有可能造成维数灾难，而对特征向量进行主成分分析可以有效避免这种情况的发生。

在进行PCA降维时，要谨慎选择累计贡献率下界，确定合适的PCA输出维数，才能有效提高正确率。

频域分段最大值提取特征向量无需经过归一化处理，是一种简单、直接、有效的故障轴承数据特征提取方法。

表10 KNN分类器在不同特征的准确率

特征	正确率
时域信号	88.2%
频域信号	89.1%
小波变换	87.0%
时域+频域+小波	93.7%
原始数据10维PCA	44.1%
时域频域及小波10维PCA特征	91.6%
时域频域及小波50维PCA特征	94.5%
频域分段最大	99.8%

4.4.2 随机森林分类器实验结果与分析

在用随机森林测试准确率之前，为了更好地确定超参数，本文测试了一些特征组合在不同树的数量下的准确率，其准确率曲线如图15所示。

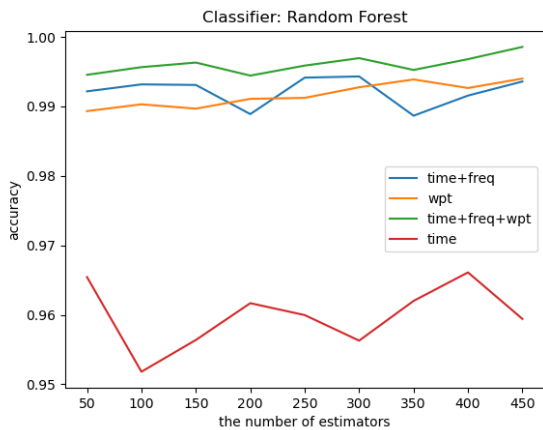


图15: 一些特征组合在不同树的数量下的准确率曲线

图中15条曲线分别表示时域与频域特征混合、时频域特征、时域与频域与时频域特征混合以及时域特征。综合来看，当树的数量为250时总体的效果最好，因此接下来的准确率检测便基于250个树的数量进行。同时，从树的数量能看出，尽管树的数量很高，但测试结果仍达到了99%以上，可以看出随机森林抗过拟合的能力之强。表1表示随机森林在训练集与测试集为7:3，对所有特征组合情况进行10次实验取F1 score平均值的准确率结果。

表11. 随机森林对于不同特征的准确率

特征	RF(trees = 250)
时域特征	96.4
频域特征	98.0
小波变换特征	99.3
时域+频域+小波特征	99.8
原始数据10维PCA	36.8
时域频域及小波10维PCA特征	96.8
频域分段最大	99.7
原始频域数据	99.8

由表11可知，RF的算法精度较高，对于不同的特征都有较强的区分能力。除了第5组实验，其余的结果都在95%以上，这说明随机森林由于只有在半数以上的基分类器出现差错时才会做出错误的预测，因而随机森林非常稳定，准确率较高。另外RF在处理时域+频域+小波特征以及原始频域数据特征时，其准确率最高，说明了这两种特征形式的可行性。

4.4.3 支持向量机实验结果与分析

本次支持向量机的实验中，我们使用python语言中的sklearn库，库中含有支持向量机分类器，我们可以自己选择不同的惩罚因子和核函数来调整我们的分类器。本次实验中，我们使用高斯核和线性核作为核函数进行实验。

首先我们使用高斯核作为支持向量机的核函数，对于支持向量机的惩罚因子C的选择，我们使用

GridSearchCV()^[27]函数，给定C的范围为0.5—3之间，通过网格搜索的方法寻找最优的惩罚因子值；最终得到C在0.8附近时的分类效果较好。随后我们使用不同的特征对训练器进行训练，并且使用训练集：测试集=7:3的方式检测训练效果，结果如表12中所示；我们发现除了对于时域特征的分类正确率能够达到95%以上，对于其余的特征分类结果均在60%以下，效果不理想，高斯核并不适用于作为该分类器训练的核函数。

表12: 高斯核SVM对不同特征的准确率

特征	SVM(高斯核)
时域特征	96.6%
频域特征	32.3%
小波变换特征	45.8%
时域+频域+小波特征	28.5%
原始数据10维PCA	52.9%
时域频域及小波10维PCA特征	24.1%
频域分段最大	39.2%
原始频域数据	22.0%

之后我们使用线性核作为核函数对分类器进行训练，我们使用的是软间隔线性分类器，惩罚因子仍设为0.8；使用训练集：测试集=7:3的方式检测训练效果，结果如表13所示：

表13: 线性核SVM对不同特征的准确率

特征	SVM(线性核)
时域特征	86.1%
频域特征	84.9%
小波变换特征	98.7%
时域+频域+小波特征	98.7%
原始数据10维PCA	37.0%
时域频域及小波10维PCA特征	97.1%
频域分段最大	99.8%
原始频域数据	99.9%

根据实验结果，我们可以发现，除了直接使用将原始数据降至10维PCA后的数据进行训练后，精度在37%，其余的分类结果均在80%以上，部分的分类结果逼近100%。从数据中可以看出线性核作为分类器的核函数有着更好的效果，数据的线性可分性较好；同时，对于多种特征的分类结果，我们可以看出：对于仅使用频域特征进行分类和运用进行了频域最大分段的数据进行分类的效果有显著差别，同时对比多种方式提取后的特征进行训练的结果与单一的提取的特征训练结果，进一步发现从时域，频域，时频域等多种方面混合提取特征能够提高训练精度；使用SVM分类器，我们发现在训练“时域+频域+小波特征”数据时的速度为0.27秒，进一步说明了SVM分类器具有结构简单，对于相同的样本相较于其他分类器训练速度较快的特点。

4.4.4 三种分类器效果的分析比较

三种分类器处理时域+频域+小波特征准确率都很高,KNN的准确率达到93.7, RF的准确率达到99.8, SVM的准确率达到98.7, 从而验证了这种特征提取方法的可行性。

特征提取后相较于直接用原始频域数据准确率有稍许降低, 可能是手动提取的特征数目较少, 导致丢失了有用信息。而原始信息包含信息丰富, 所以准确率高。

从PCA降到50维和10维的结果可以看出降维的维度影响准确率, 维度越低可能导致丢失信息, 从而导致准确率降低, 但加快了训练速度, 所以二者需要做一个权衡。

5 总结

本文针对轴承在正常工作和不同类型故障下的振动数据十分类问题, 采用了时域、频域、时频域的特征提取方法, 构建了不同的特征空间; 接着, 本文进行了部分特征相关度的分析, 分别采用不同目标维度的PCA降维对特征空间做降维处理; 最后在随机森林、KNN以及SVM分类器中进行了实验并得出了最终准确率趋于1的特征空间及分类器。分别是:

(1) 频域原始数据与三种分类器其中之一的组合。我们可以看到, 频域原始数据也能在KNN、SVM或随机森林中都达到趋于1的准确率, 说明频域里的信息对于这三类分类器是完全够用的, 相较于时域原始数据, 频域数据没有相位不同的问题。

(2) 频域分段最大值特征与三种分类器之一的组合。频域原始数据虽然能达到较好的分类效果, 但是计算量较大, 效率不高。采用传统方式特征提取后, 9个频域特征在三种分类器中都没有取得很好的效果。这是由量纲不统一而引发的。在引入频域分段最大值特征后, 这个问题得以解决。

此外, 将不同域的特征结合起来, 虽然增加了特征空间维度, 加大了计算量, 但能有效提高分类正确率; PCA降维能以少量准确率的损失换来特征空间维度的大幅减少, 是一种高效有用的方法。

参考文献

[1] 陈仁祥, 黄鑫, 杨黎霞, 等. 基于卷积神经网络和离散小波变换的滚动轴承故障诊断[J]. 振动工程学报, 2018, 31 (05): 883-891. (C hen Renxiang, Huang Xin, Yang Lixia, et al. Rolling bearing fault identification based on convolution neural network and discrete wavelet transform [J]. Journal of Vibration Engineering, 2018, 31 (05): 883-891.)

[2] 彭成, 王松松, 贺婧, 李凤娟. 基于离散小波变换和随机森林的轴承故障诊断研究[J/OL]. 计算机应用研究: 1-6[2020-06-16]. <https://doi.org/10.19734/j.issn.1001-3695.2019.09.0633>.

[3] 彭宅铭, 程龙生, 詹君, 姚启峰. 基于多特征提取和改进马田系统的滚动轴承故障分类方法研究[J]. 振动与冲击, 2020, 39(06): 249-256.

[4] X. Yu and X. Yu, "Novel Text Classification Based on K-Nearest Neighbor," 2007 International Conference on Machine Learning and Cybernetics, Hong Kong, 2007, pp. 3425-3430, doi: 10.1109/ICMLC.2007.4370740.

[5] Breiman L. Random forests [J]. Machine learning, 2001, 45 (1): 5-32.

[6] Yu Yang, Dejie Yu, Junsheng Cheng, A fault diagnosis approach for roller bearing based on IMF envelope spectrum and SVM, Measurement, Volume 40, Issues 9 - 10, 2007, Pages 943-950, ISSN 0263-2241

[7] Zuqiang Su, Baoping Tang, Ziran Liu, Yi Qin, Multi-fault diagnosis for rotating machinery based on orthogonal supervised linear local tangent space alignment and least square support vector machine, Neurocomputing, Volume 157, 2015, Pages 208-222,

[8] Gu, Y., Zhou, X., Yu, D. et al. Fault diagnosis method of rolling bearing using principal component analysis and support vector machine. J Mech Sci Technol 32, 5079 - 5088 (2018). <https://doi.org/10.1007/s12206-018-1004-0>

[9] Liang Guo, Naipeng Li, Feng Jia, Yaguo Lei, Jing Lin, A recurrent neural network based health indicator for remaining useful life prediction of bearings, Neurocomputing, Volume 240, 2017, Pages 98-109, ISSN 0925-2312,

[10] Duong BP, Kim JM. Non-Mutually Exclusive Deep Neural Network Classifier for Combined Modes of Bearing Fault Diagnosis. Sensors (Basel). 2018;18(4):1129. Published 2018 Apr 7. doi:10.3390/s18041129

[11] Fei. Zhang A denoising purification methods of speech signal based on wavelet transform [J] Electronic Measurement Technology:, 32 (6) (2009), pp. 68-71

[12] Wang Chunli, Zhang Chunlei, Zhang pengtu, Denoising algorithm based on wavelet adaptive threshold, Procedia, Volume 24, Part A, 2012, Pages 678-685, ISSN 1875-3892,

[13] 程秀芳, 王鹏. 基于时域和频域分析的滚动轴承故障诊断[J]. 华北理工大学学报(自然科学版), 2020, 42(01): 58-64

[14] 陈法法, 杨晶晶, 肖文荣, 程珩, 张发军. Adaboost_SVM 集成模型的滚动轴承早期故障诊断[J]. 机械科学与技术, 2018, 37(02): 237-243.

[15] 董绍江. 基于优化支持向量机的空间滚动轴承寿命预测方法研究[D]. 重庆大学, 2012.

[16] Varanis, Marcus & Pederiva, Robson. (2015). Wavelet Packet Energy-Entropy Feature Extraction and Principal Component Analysis for Signal Classification. 10.5540/03.2015.003.01.0471.

[17] B. Liu. Selection of wavelet packet basis for rotating machinery fault diagnosis, Journal of Sound and Vibration 284 567 - 582. 2005.

[18] 郭伟超, 赵怀山, 李成, 李言, 汤奥斐. 基于小波包能量谱与主成分分析的轴承故障特征增强诊断方法[J]. 兵工学报, 2019, 40(11): 2370-2377.

[19] 俞啸, 董飞, 高彬, 张立. 基于 HHT 和 PCA 的滚动轴承故障状态识别方法研究[J]. 电子设计工程, 2018, 26(11): 28-32.

[20] 刘波, 宁芊. 基于特征融合和 KPCA_GA-SVM 的滚动轴承故障诊断[J]. 现代计算机(专业版), 2019(11): 32-38.

[21] Jiayu Chen, Chen Lu, Hang Yuan. Bearing fault diagnosis based on active learning and random forest, Vibroengineering PROCEDIA, Vol. 5, 2015, p. 321-326.

- [22] 彭成,贺婧,唐朝晖,陈青,桂卫华.基于双维度 EKNN 的滚动轴承早期故障分类算法[J/OL].计算机集成制造系统:1-20[2020-06-14].<http://kns.cnki.net/kcms/detail/11.5946.TP.20200323.1053.002.html>.
- [23] 路敦利,宁芊,杨晓敏.KNN-朴素贝叶斯算法的滚动轴承故障诊断[J].计算机测量与控制,2018,26(06):21-23+27.
- [24] 陈法法,李冕,陈保家,陈从平.基于混合域特征集与加权 KNN 的滚动轴承故障诊断[J].机械传动,2016,40(08):138-143.
- [25] Dasom Seo,Euncheol Kang,Yu-mi Kim,Sun-Young Kim,Il-Seok Oh,Min-Gul Kim. SVM-based waist circumference estimation using Kinect[J]. Computer Methods and Programs in Biomedicine,2020,191.
- [26] [3] Ammal Fannoush Khalifah.Support vector machines for petrophysical modelling and lithoclassifica [D].Canada:University of Calgary,2011.
- [27] 王晋陶.可变步长网格搜索法结合 LIBSVM 预测风机故障研究[J].南方农机,2020,51(11):93+95.